概率论

李秋满

2026 年 4 月 10 日

目录

1 测度论 **5**
1.1 概率空间 5
1.2 分布 8
1.3 随机变量 9
1.4 积分 10
1.5 积分的性质 10
1.6 期望值 11
1.6.1 期望 11
1.6.2 不等式 11
1.7 积测度与 Fubini 定理 13
1.8 Remark 14

2 大数定律 **17**
2.1 独立性 17
2.1.1 独立的充分条件 19
2.1.2 独立性，分布，与期望 20
2.1.3 独立随机变量和 21
2.1.4 构造独立的随机变量 22
2.2 弱大数定律 22
2.2.1 L2 弱收敛定律 22
2.2.2 三角阵列 23
2.2.3 截断 25
2.3 Borel-Cantelli 引理 26

Chapter 1

测度论

1.1 概率空间

Definition 1.1.1. 概率空间：$(\Omega, \mathcal{F}, P)$

1. Ω:全体结果
2. $\mathcal{F}$:事件域
3. P:概率

Definition 1.1.2 (σ代数)**.** $\mathcal{F}$是一个σ代数，即

1. $A \in \mathcal{F}$, 推出$A^c \in \mathcal{F}$
2. $A_n \in \mathcal{F}$, 推出$\bigcup\limits_n A_n \in \mathcal{F}$

Theorem 1.1.1. $(\Omega, \mathcal{F})$是一个测度空间，意味着可以接受一个测度.

Definition 1.1.3 (测度)**.** .μ:

1. $\mu(A) \geq \mu(\emptyset) = 0$
2. A_n是一列无交集合，$\mu(+_n A_n) = \sum_n \mu(A_n)$

如果$\mu(\Omega) = 1$，则为概率测度.

首先研究测度性质:

Theorem 1.1.2. *1.* $A \subset B, \mu(A) \geq \mu(B)$

2. $A \subset \bigcup\limits_n A_n, \mu(A) \leq \sum_n \mu(A_n)$

3. $A_i \uparrow A, \mu(A_i) \uparrow \mu(A)$

4. $A_i \downarrow A, \mu(A_i)$存在, $\mu(A_i) \downarrow \mu(A)$

下面研究如何为一个测度空间赋予一个测度，并且在实数域和欧式空间中做出更多结论.

Definition 1.1.4. $\sigma(\mathcal{A})$是最小的包含$\mathcal{A}$的σ代数.

Definition 1.1.5. $\mathcal{R}^d$是由开集生成的σ代数，叫做Borel集

Definition 1.1.6. Stieltjes测度函数

1. F不减
2. F右连续

Theorem 1.1.3. *每一个Stieltjes测度函数都可以生成一个在$(\mathbf{R}, \mathcal{R})$上的测度，并且满足*

$$\mu((a,b]) = F(b) - F(a) \tag{1.1}$$

这是我们要证明的核心的定理，它说明了每个分布函数可以完全的反映出一个随机变量给出的测度.

定理是由从半代数的构造开始的：

Definition 1.1.7. 半代数是一个幂集的子集S，满足

1. 在交集下封闭
2. 任意集合的补是半代数中有限集合的无交并

Definition 1.1.8. 代数是一个幂集的子集，满足在交和补的意义下封闭

Definition 1.1.9. 在代数上可以定义测度，测度满足：

1. $\mu(A) \geq \mu(\emptyset) = 0$
2. A_n是一列代数中无交集合,$A = +_n A_n$也在代数中，$\mu(+_n A_n) = \sum_n \mu(A_n)$

Definition 1.1.10. σ有限是指存在一列$A_n \in \mathcal{A}$,满足$\mu(A_n) < \infty, \underset{n}{\cup} A_n = \Omega$

Lemma 1.1.4. *S是半代数，$\bar{S} = \{S$中元素的无交有限并$\}$是一个代数.*

从半代数到代数到σ代数的过程中，相应的，测度就可以从半代数扩充到σ代数.这一步要利用测度论中的$\pi - \lambda$定理，证明过程极为复杂，在这里不写

Theorem 1.1.5. $\mathcal{S}$是一个半代数，μ是定义在$\mathcal{S}$上的函数，满足：

1. 如果$S, S_i \in \mathcal{S}$,$S = +_{i=1}^{n} S_i$那么$\mu(S) = \sum \mu(S_i)$
2. 如果$S, S_i \in \mathcal{S}$,$S = +_{i+1} S_i$那么$\mu(S) < \sum \mu(S_i)$

那么μ有唯一的扩张$\bar{\mu}$是$\bar{\mathcal{S}}$上的测度.
如果$\bar{\mu}$是σ有限的，说明有一个唯一的扩张是$\sigma(\mathcal{S})$上的测度.

最后的准备工作是下面的引理

Lemma 1.1.6. 如果只要求1成立，我们有

1. 如果 $A, B_i \in \bar{\mathcal{S}}, A = +_{i=1}^{n} B_n$那么$\bar{\mu}(A) = \sum \mu(B_i)$
2. 如果$A, B_i \in \bar{\mathcal{S}}, A \subset +_{i=1}^{n} B_n$那么$\bar{\mu}(A) = \sum \mu(B_i)$

现在我们开始证明Theorem 1.1.3

证明. 设$\mathcal{S}$是区间$(a, b]$构成的半代数.在$\mathcal{S}$上定义μ为$F(b) - F(a)$. 只需要验证Theorem1.1.5上的两个条件即可，首先1是显然的，关键在于证明2.

假设$-\infty < a < b < \infty$,$(a, b] \subset \cup(a_i, b_i]$,不失一般性，假设$-\infty < a_i < b_i < \infty$.选取$\delta$,使得$F(a+\delta) < F(a) + \epsilon$,选取$\eta_i$,使得$F(b_i + \eta_i) < F(b_i) + 2^{-i}\epsilon$.开区间$(a_i, b_i + \eta_i)$可以覆盖$[a+\delta, b]$那么有子覆盖$(\alpha_i, \beta_i)$.

计算测度可以得到

$$F(b) - F(a+\delta) = \sum F(\beta_i) - F(\alpha_i) \tag{1.2}$$

$$F(b) - F(a) = \epsilon + \sum 2^{-i}\epsilon + \sum F(b_i) - F(a_i) \tag{1.3}$$

令ϵ趋于无穷小证明结论。

□

这个定理之所以重要，在于它从一个分布函数得到了一个概率测度，就说明了我们的研究可以通过分布转移到实数上操作。

下面开始研究在$\mathbb{R}^d$上的测度.同样有定义：

Definition 1.1.11. Stieltjes测度函数

1. F不减
2. F右连续
3. $x_n \downarrow -\infty, \forall n, F(x) \downarrow 0$; $X_n \uparrow \infty, \forall n, F(x) \uparrow 1$
4. $\triangle_A F \geq 0$,对于任何的长方体

注意只有前三个是不够的

Example 1.1.1. 定义

$$F(x_1,x_2)=\begin{cases}1, & x_1,x_2\geq 1\\ 2/3 & x_1\geq 1, 0\leq x_2\leq 1\\ 2/3 & x_2\geq 1, 0\leq x_1\leq 1\\ 0 & \text{其他}\end{cases} \tag{1.4}$$

计算$\mu(1,1)=-1/3$显然，这种函数不应该作为分布函数出现.

所以我们要求至少半代数中的元素的测度应该至少大于或等于0.$A=\Pi(a_i,b_i]$.$v\in V=\Pi\{a_i,b_i\}$,记$sgn(v)=-1^{a_i\text{出现次数}}$，我们需要要求$\triangle_A F=\sum sgn(v)F(v)\geq 0$

同样有定理

Theorem 1.1.7. *每一个Stieltjes测度函数都可以生成一个在$(\mathbf{R}^d,\mathcal{R}^d)$上的测度，并且满足*

$$\mu(A)=\triangle_A F \tag{1.5}$$

1.2 分布

Definition 1.2.1 (随机变量)**.** X是定义在$(\Omega,\mathcal{F})$上的函数，如果$X^{-1}(B)=\{X\in B\}\in\mathcal{F}$那么$X$是一个随机变量

Definition 1.2.2 (示性函数)**.** 1_A

Definition 1.2.3 (分布)**.** $F(A)=P(X\in A)$

只要在$(-\infty,x)$上确定了分布的取值，我们也就确定了整个分布

Definition 1.2.4 (分布函数)**.** $F(x)=F((\infty,x))$

Theorem 1.2.1. *分布函数的性质*

1. *F不减*
2. *F右连续*
3. *$x\uparrow\infty$,$F(x)\to 1$; $x\downarrow-\infty$,$F(x)\to 0$*
4. *记$F(x^-)=\lim\limits_{y\uparrow x}F(y)$,那么$F(x^-)=P(X<0)$*
5. *$P(X=x)=F(x)-F(x^-)$*

如果一个函数具有上面的性质，那么这个函数就是一个分布函数，下面的证明不仅仅是证明了分布函数的充分条件，也给出了一个分布函数的实现方法.

Theorem 1.2.2. *如果一个函数F具有性质1，2，3那么它是某个随机变量的分布函数*

证明. 给定概率空间$(\Omega, \mathcal{F}, P) = ((0,1), \mathcal{R}, \mu)$,定义随机变量

$$X(\omega) = \sup\{x : F(x) < \omega\} \tag{1.6}$$

只要证明 $\{\omega : X(\omega) \le x\} = \{\omega : \omega \le F(x)\}$就完成了定理的证明.

如果$\omega \in \{\omega : \omega \le F(x)\}$,则$x \notin \{x : F(x) < \omega\}$,也就是$x \ge X(\omega)$.

如果$\omega \notin \{\omega : \omega \le F(x)\}$,则$\omega > F(x)$,由于右连续性，有$r > 0$，$F(x+r) < \omega$,则$X(\omega) \ge x+r > x$. □

下面介绍一些定义和例子

Example 1.2.1. 如果X, Y同分布，记为$X \overset{d}{=} Y$.

Example 1.2.2. 如果X的分布函数有$F(x) = \int_{-\infty}^{x} f(y)d\mu$,那么$f(y)$是$X$的密度函数.

Example 1.2.3 (Uniformly distribution)**.**

$$F(x) = \begin{cases} 0 & x \le 0 \\ x & 0 < x \le 1 \\ 1 & x > 1 \end{cases} \tag{1.7}$$

Example 1.2.4 (Exponential distribution)**.**

$$F(x) = \begin{cases} 0 & x \le 0 \\ 1 - \exp(-\lambda x) & 0 < x \end{cases} \tag{1.8}$$

Example 1.2.5 (Standard normal distribution)**.**

$$f(x) = (2\pi)^{-1} \exp(-x^2/2) \tag{1.9}$$

对于正态分布的分布函数，我们有一个估计

Theorem 1.2.3.

$$(x^{-1} - x^{-3}) \exp(-x^2/2) \le \int_{y=x}^{\infty} \exp(-x^2/2) \le x^{-1} \exp(-x^2/2) \tag{1.10}$$

证明. $\int_{y=x}^{\infty} \exp(-x^2/2) = \int_0^{\infty} \exp(-x^2/2 - xy - y^2/2) \le x^{-1} \exp(-x^2/2)$

另外一边可以直接放缩后积分. □

1.3 随机变量

首先说明，一般的定义，称为随机元素(random element),如果映到实数上，那么叫做随机变量，如果映射到实数数组，叫做随机向量.

Theorem 1.3.1. $X^{-1}(A) \in \mathcal{F}$,$A \in \mathcal{A}$,$\mathcal{S} = \sigma(\mathcal{A})$,那么$X$可测

证明. $\mathcal{B} = \{B : \{X \in B\} \in \mathcal{F}\}$,易证$\mathcal{B}$是一个sigma代数，由于$\mathcal{A} \subset \mathcal{B}$,则$\mathcal{S} \subset \mathcal{B}$ □

对于随机变量来说，只要证明$X < x$可测，就可以证明X可测.

Definition 1.3.1. $\sigma(X) = \{\{X \in A\} : A \in \mathcal{S}\}$

Theorem 1.3.2. 如果X可测，f也可测，则$f(X)$也可测

Theorem 1.3.3. 如果X_i可测$(i = 1, 2, \cdots n)$，f可测，$f(X_1, X_2, \cdots, X_n)$可测

这些工具可以帮助我们判断很多映射是否是随机变量，其中有些重要的结论值得作为定理记住：

Theorem 1.3.4. $X_1 + X_2 + \cdots + X_n$是一个随机变量

Theorem 1.3.5. $\inf X_n, \sup X_n, \limsup X_n, \liminf X_n$都是随机变量

1.4 积分

积分不是概率论研究的重点，所以积分的构造应该省略，积分有些最基本的性质：

Theorem 1.4.1. 性质:

1. $f \geq 0, a.e., \quad \int f d\mu \geq 0$
2. $\forall a \in \mathbb{R}, \int a f d\mu = a \int f d\mu$
3. $\int f + g d\mu = \int f d\mu + \int g d\mu$

1.5 积分的性质

首先是两个不等式的性质：

Theorem 1.5.1 (Jensen's inequality)**.** φ是一个凸函数，则$\varphi(\int f d\mu) \leq \int \varphi(f) d\mu$

证明. 记$c = \int f d\mu$,找一个线性函数$l(x) = ax + b$,其中$l(c) = \varphi(c)$. 由于φ凸：

$$\lim_{y \uparrow x} \frac{\varphi(x) - \varphi(y)}{x - y} \leq \lim_{y \downarrow x} \frac{\varphi(x) - \varphi(y)}{x - y} \tag{1.11}$$

取$x = c$,取a介于两个极限之间,则$l(x) \leq \varphi(x)$.那么$\int \varphi(f) d\mu \geq \int l(f) d\mu \geq a \int f d\mu + b = \varphi(\int f d\mu)$ □

Theorem 1.5.2 (Holder inequality)**.** $\int |fg| d\mu \leq ||f||_p ||g||_q$,其中$p > 1, q > 1, 1/p + 1/q = 1$

下面讨论收敛函数列积分的性质：

Theorem 1.5.3 (Bounded convergence theorem). 假设f_n在一个有限测度的集合E上不消失，而且$|f_n| < M$,$f_n \to f a.e.$,则f可积，$\int f_n d\mu \to \int f d\mu$

Theorem 1.5.4 (Fatou's Lemma). $f_n \leq 0$,那么$\liminf \int f d\mu \geq \int \liminf f d\mu$

Theorem 1.5.5 (单调收敛定理). 如果 $f_n \geq 0$ 且 $f_n \uparrow f$ 那么 $\int f_n \, d\mu \uparrow \int f \, d\mu$

证明. 用Fatou's Lemma可以直接证明：

$\liminf_{n\to\infty} \int f_n \, d\mu \geq \int f \, d\mu$

$\limsup_{n\to\infty} \int f_n \, d\mu \leq \int f \, d\mu$

$\Rightarrow \int f_n \, d\mu \uparrow \int f \, d\mu$ □

Theorem 1.5.6 (有界收敛定理). 如果 $f_n \to f$ 几乎处处且 $|f_n| \leq g$ 对所有 n，并且 g 可积，$\int f_n \, d\mu \to \int f \, d\mu$

1.6 期望值

1.6.1 期望

Definition 1.6.1 (期望). $E[X] = \int X \, dP$

期望最基本的性质是：

Theorem 1.6.1. $E(X+Y) = E(X) + E(Y)$

$E(aX+b) = aE(X) + b$

$X \geq Y \Rightarrow E(X) \geq E(Y)$

1.6.2 不等式

做数学分析几乎最重要的工具应该是不等式，在期望我们首先研究不等式,这些不等式在最基本的概率论课程上已经讲过，所以不加证明。

Theorem 1.6.2. 假设 ψ 是凸函数，$E[\psi(X)] \geq \psi(E(X))$

Theorem 1.6.3. $E|XY| \leq \|X\|_p \|Y\|_q$

Theorem 1.6.4 (切比雪夫不等式). $\psi : \mathbb{R} \to \mathbb{R}$, $\psi \geq 0$, $A \in \mathbb{R}$ $i_A = \inf\{\psi(y) : y \in A\}$

$i_A P(X \in A) \leq E[\psi(X) : X \in A] \leq E[\psi(X)]$

Theorem 1.6.5 (马尔可夫不等式). $P(|X| \geq a) \leq \frac{E(|X|^2)}{a^2}$

极限

积分的极限性质就是期望的极限性质

Theorem 1.6.6 (Fatou 引理). $\liminf E(X_n) \geq E(\liminf X_n)$

Theorem 1.6.7 (单调收敛引理). $0 \leq X_n \uparrow X,\ E(X_n) \uparrow E(X)$

Theorem 1.6.8 (有界收敛引理). $X_n \to X,\ |X_n| \leq Y,\ E|Y| < \infty\ E(X_n) \to E(X)$

Theorem 1.6.9. 假设 $X_n \to X$ 当 $n \to \infty$. 令 g, h 为连续函数，满足
(i) $g(x) \to \infty$ 当 $|x| \to \infty$
(ii) $|h(x)|/g(x) \to 0$ 当 $|x| \to \infty$
(iii) $E[g(X_n)] \leq K$ 对所有 n
那么 $E[h(X_n)] \to E[h(X)]$

证明：通过从 h 中减去一个常数,不失一般性 $h(0) = 0$。取 M 足够大使得 $P(|X| \geq M) = 0$ 且当 $|x| \geq M$ 时 $g(x) > 0$。给定随机变量 Y，令 $\overline{Y} = Y\mathbf{1}(|X| \leq M)$。由于 $P(|X| = M) = 0$。

$\overline{X}_n \to \overline{X}$ 当 $n \to \infty$. 由于 $h(\overline{X}_n)$ 有界且连续，根据有界收敛定理:$\sum h(\overline{X}_n) \to E(h(\overline{X}))$ 为了控制截断的影响： $|E(h(\overline{Y})) - E(h(Y))| \leq E(|h(\overline{Y}) - h(Y)|) \leq E(h(Y)|Y \geq M) \leq \epsilon_M E(g(Y))$其中$\epsilon_M = \sup\{|h|/g\} : x > M$

令$Y = X_n$,有$E(|h(\overline{X_n}) - h(X_n)|) \leq \epsilon_M K$

由Fatou's Lemma $\liminf E(g(X_n)) \geq E(g(X))$,同理

$E(|h(\overline{X}) - h(X)|) \leq \epsilon_M K$

计算期望

计算期望的核心任务是将无法计算的抽象的概率空间转化到可以熟练计算的实数上来计算.

Theorem 1.6.10 (变量代换公式). X是一个到$(S, \mathcal{S})$的随机元素，其中有分布μ,,f是

证明. 证明方法是采用典型方法

1. 示性函数：设$B \subset \mathcal{S}$,$f = 1_B(X)$

$$Ef = \int_\Omega 1_B \mathrm{d}\mu = \int_S 1_{X(B)} \mu \mathrm{d}y$$

2. 简单函数：$f = \sum_1^n 1_{A_i}$

$$Ef = \int_\Omega \sum_1^n 1_{A_1} \mathrm{d}\mu = \sum_1^n \int_\Omega 1_{A_1} \mathrm{d}\mu = \int_S \sum_1^n 1_{X(A_i)} \mu \mathrm{d}y$$

3. 非负函数，我们总可以取一列简单函数上升到非负函数，也就是$f_n \uparrow f$

$$Ef = \lim_{n\to\infty} \int_\Omega f_n \mathrm{d}\mu = \lim_{n\to\infty} \int_S f_n \mu \mathrm{d}y = \int_S f \mu \mathrm{d}y$$

4. 可积函数，由于$Ef = Ef^+ - Ef^-$,可以证明等式成立.

□

Definition 1.6.2 (随机变量的矩). 第 k 阶矩：$E(X^k)$ 。
方差定义为： $\mathrm{Var}(X) = E[(X-\mu)^2]$

1.7 积测度与 Fubini 定理

设 $(X, \mathcal{A}, \mu_1)$ 与 $(Y, \mathcal{B}, \mu_1)$ 为两个 σ-有限测度空间. 定义 $\Omega = X \times Y$ 其中$S = \{A \times B \mid A \in \mathcal{A}, B \in \mathcal{B}\}$, S是一个半代数,记 $\mathcal{F}$ 是由 S 生成的 σ-代数. 可以由 μ_1 μ_2 自然地导出 $\mathcal{F}$ 上的测度.

Theorem 1.7.1. 在 $\mathcal{F}$ 上有一个唯一的测度满足

$$\mu(A \times B) = \mu_1(A) \times \mu_2(B)$$

证明. 这是一个证明测度的唯一存在的命题.我们根据$\mu(A \times B) = \mu_1(A) \times \mu_2(B)$，我们在半代数上面定义了一个函数.而且它是 σ 有限的，因为 μ_1, μ_2 都是σ 有限的.所以我们只用验证两条性质，在这里，其实只用验证一条：

证明 $\mu(A \times B) = \sum_i \mu(A_i \times B_i)$

对 A_i, B_i 加细，把他们分成小方格，只用证明$\mu(A \times B) = \sum_{m,n} \mu(A_m \times B_n)$.这是显然的，由于 $\mu_1\mu_2$ 的可列可加性. □

我们证明了两个空间的积，也就证明了有限的空间的积具有相同的性质.

Theorem 1.7.2. 如果 $f > 0$ 或者 $\int |f| \mathrm{d}\mu < \infty$,那么

$$\int_X \int_Y f(x,y)\mu_1(\mathrm{d}x)\mu_2(\mathrm{d}y) = \int_{X \times Y} f(x,y)\mu(\mathrm{d}x\mathrm{d}y) = int_Y \int_X f(x,y)\mu_1(\mathrm{d}y)\mu_2(\mathrm{d}x)$$

Remark 1.7.1. 这个定理的证明依旧是利用典型方法，但是困难的地方并不在于三步的扩张，而是在于示性函数的证明，从几何上理解就是求一个物体的体积，可以先对一个平面求面积，然后再将这些面积加起来得到体积.但是这个过程在抽象的测度意义下并不容易.

Definition 1.7.1. 记$E_x = \{y : (x,y) \in E\}$,叫做横截面

首先解决第一次可积的问题.

Lemma 1.7.3. 如果$E \in \mathcal{F}$,那么$E_x \in \mathcal{B}$

证明. 如果$E = A \times B$,$E_x = B \in \mathcal{B}$.

$(E_x)^c = E_x^c$,$\cup_n E_x = (\cup_n E)_x$,说明 $\mathcal{E} = \{E : E_x \in \mathcal{B}\}$ 是一个 σ 代数.

$\mathcal{F} \subset \mathcal{E}$ 从而证明了结论. □

然后解决第二次可积的问题.

Lemma 1.7.4. 如果 $E \in \mathcal{F}$,$g(x) = \mu_2(E_x)$ 是 $\mathcal{A}$ 可测的，并且

$$\int_X g \mathrm{d}\mu_1 = \mu(E)$$

证明. 问题的证明应当采用$\pi - \lambda$定理.

首先，如果$E = A \times B$, $g(x) = \mu_2(E_x) = \mu_2(B)1_A$, 是 $\mathcal{A}$ 可测的.而且 $\int_X g \mathrm{d}\mu_1 = \mu_1(A)\mu_2(B) = \mu(E)$.

这样的 E 构成了一个 $\pi -$ system,我们记作S.

下面寻找$\lambda -$ system.首先，我们不妨假设μ_1, μ_2都是有限的.因为 μ_1, μ_2 都是σ有限的，可以找到A_n, B_n,分别测度有限，并且上升到全集，考虑对一个函数f的积分，只需考虑f在 $A_n \times B_n$ 上的积分，也就是$E \cap A_n \times B_n$.

下面令λ-system 是满足上述积分等式的集合，我们记作$\mathcal{E}$验证λ-system的三条性质.首先，全集在集合中，这是显然的.而后,如果$A_i \in \mathcal{E}, A_i \uparrow A$,那么$A \subset \mathcal{E}$,由单调上升定理立即得到.最后验证$A, B \subset \mathcal{E}$,$A \subset B$,则$B - A \subset \mathcal{E}$.

我们有

$$\int \mu_2(A_x)\mathrm{d}\mu_1 = \mu(A)$$

$$\int \mu_2(B_x)\mathrm{d}\mu_1 = \mu(B)$$

两边相减

$$\int \mu_2(A_x)\mathrm{d}\mu_1 - \int \mu_2(B_x)\mathrm{d}\mu_1 = \mu(B - A)$$

其中左侧$\int \mu_2(A_x)\mathrm{d}\mu_1 - \int \mu_2(B_x)\mathrm{d}\mu_1 = \int \mu_2(A_x) - \mu_2(B_x)\mathrm{d}\mu_1 = \int \mu_2(A_x - B_x)\mathrm{d}\mu_1 = \int \mu_2((A - B)_x)\mathrm{d}\mu_1$. 所以

$$\int \mu_2((A - B)_x)\mathrm{d}\mu_1 = \mu(B - A)$$

证明结论. □

同样的，采用典型方法，证明Fubini定理.

1.8 Remark

这里有些问题仍然值得研究,首先第一节定理的证明中第二条性质为何要使用不等式,具体地说，是不是反向的不等式是显然的.其次在Fatou引理的证明中，用到的有界收敛定理，要求的是依概率收敛，然而在证明过程中，我们得到的是点点收敛，这一点并不是显然的.最后是一个关于期望的定理是否可以证明出依概率收敛的结论.

在这一节，我们来讨论上面提到的一些问题.

1

Theorem 1.8.1. $\mathcal{S}$是一个半代数，μ是定义在$\mathcal{S}$上的函数，满足：

1. 如果$S, S_i \in \mathcal{S}$,$S = +_{i=1}^n S_i$那么$\mu(S) = \sum \mu(S_i)$
2. 如果$S, S_i \in \mathcal{S}$,$S = +_{i+1} S_i$那么$\mu(S) \leq \sum \mu(S_i)$

那么μ有唯一的扩张$\bar{\mu}$是$\bar{\mathcal{S}}$上的测度.

如果$\bar{\mu}$是σ有限的，说明有一个唯一的扩张是$\sigma(\mathcal{S})$上的测度.

我们应当要求$\mu(S) \geq \mu(\emptyset) = 0$.

第二条反向的不等式不能用下面的方法在半代数中直接加以证明，令 $A = +_i A_i$,其中$A, A_i \in \mathcal{S}$,记$C_n = +_n^\infty A_i$,则$\mu(A) = \sum_1^n \mu(A_i) + \mu(C)$.如果$C$在半代数中，我们有$\mu(A) \geq \sum_1^n \mu(A_i) \to \sum \mu(A_i)$.但是$C$未必是一个在半代数中的集合.

我们取$\mathcal{S}$为全体左闭右开的区间,取$A = [0,1)$,$A_i = [1-1/i, 1-1/(i+1))$,再交换A_i的顺序，即$B_{2i-1} = A_{2i}, B_{2i} = A_{2i-1}$,$A = +_i B_i$.而$C_{2n+1} \notin \mathcal{S}$.这说明$C$未必是一个在半代数中的集合.

想要证明上面的不等式成立，至少应该扩充到代数上进行操作.

2 Fatou引理的证明

Theorem 1.8.2. f_n是一组非负的函数，则$\liminf \int f \mathrm{d}\mu \geq \int \liminf f_n \mathrm{d}\mu$.

证明. 取$g_n = \inf_{m \geq n} f_n$,则$g_n \uparrow g = \liminf f_n$,由于$\int f_n \mathrm{d}\mu \geq \int g_n \mathrm{d}\mu$,只要证明 $\liminf \int g_n \mathrm{d}\mu \geq \int g \mathrm{d}\mu$即可.

取$E_m \uparrow \Omega$,取$h_n = g_n 1_{E_m} \wedge n$,所以$h_n \uparrow g 1_{E_m}$,$a.e.$.

现在，由于在E_m上是一个有限测度，点点收敛就是依测度收敛,所以，由有界收敛定理,$\int g 1_{E_m} \mathrm{d}\mu = \lim\limits_{n\to\infty} \int h_n \mathrm{d}\mu$

$\liminf \int g_n \mathrm{d}\mu \geq \lim\limits_n \int h_n \mathrm{d}\mu = \int g 1_{E_m} \mathrm{d}\mu$

由于m是任意的，所以$\liminf \int g_n \mathrm{d}\mu \geq \int g \mathrm{d}\mu$ □

3

Theorem 1.8.3. 假设 $X_n \to X$ 当 $n \to \infty$. 令 g, h 为连续函数，满足

(i) $g(x) \to \infty$ 当 $|x| \to \infty$

(ii) $|h(x)|/g(x) \to 0$ 当 $|x| \to \infty$

(iii) $E[g(X_n)] \leq K$ 对所有 n

那么 $E[h(X_n)] \to E[h(X)]$

我们问这个定理是不是可以有依概率收敛的版本.是有的,证明的核心是在定理的基础上利用B-C引理.

Theorem 1.8.4. 假设 $X_n \to X$ 在概率下收敛,当 $n \to \infty$. 令 g, h 为连续函数，满足

(i) $g(x) \to \infty$ 当 $|x| \to \infty$

(ii) $|h(x)|/g(x) \to 0$ 当 $|x| \to \infty$

(iii) $E[g(X_n)] \leq K$ 对所有 n

那么 $E[h(X_n)] \to E[h(X)]$

证明. 即$y_n = E[h(X_n)], y = E[h(X)]$,我们其实是要证明一个数列收敛，我们只要证明任何子列y_{nm}都有一个子列的子列y_{nmk}收敛到y.现在我们取X_{nmk}是子列y_{nm}对应随机变量子列X_{nm}的几乎必然收敛子列.立刻得到$y_{nmk} \to y$.因而我们证明了结论. □

我们讨论一下$\pi - \lambda$定理的用法.$\pi - \lambda$定理广泛用于求某一个σ-代数满足一个积分恒等式.这是因为首先，对于σ-代数来说,我们需要验证可列可加性,但是关于测度的积分只保证不交的可加性,所以

直接验证会比较困难.其次,λ system 的要求天然与积分的性质相符合,查缉与积分的可加性对应,单调上升的集合与单调收敛定理对应,所以从$\pi-\lambda$定理出发,我们可以相对轻松的证明结论.

还有关于有限的讨论,在很多情况下,我们会要求一个测度或者集合有限,或者测度的σ有限.这某种程度上是为了避免无穷减无穷的情况发生，比如Fubini定理要求σ有限就是这个道理.

Chapter 2

大数定律

2.1 独立性

首先介绍两个之间的独立性:

Definition 2.1.1. A, B是两个事件,A, B独立是指$P(AB) = P(A)P(B)$.

Definition 2.1.2. X, Y是两个随机变量，X, Y独立是指任取$A, B \in \mathcal{R}$,$\{X \in A\}, \{Y \in B\}$独立.

Definition 2.1.3. $\mathcal{A}, \mathcal{B}$是两个事件域，$\mathcal{A}, \mathcal{B}$独立是指任取$A \in \mathcal{A}, B \in \mathcal{B}$,$A, B$独立

第一个定义是第二个的特例，第二个定义是第三个的特例.

Theorem 2.1.1.

1. 如果A, B 独立，那么A^c, B;B^c, A,A^c, B^c均独立.
2. A, B独立当且仅当$1_A, 1_B$独立.

证明. 显然. □

Theorem 2.1.2.

1. 如果X, Y独立，那么$\sigma(X), \sigma(Y)$独立.
2. 如果$\mathcal{A}, \mathcal{B}$独立，那么$X \in \mathcal{A}, Y \in \mathcal{B}$独立.

证明. 显然. □

下面我们定义多个的情形:
对于无限个的情况，我们通过任意有限个独立来定义.

Definition 2.1.4. $\mathcal{F}_1, \mathcal{F}_2, \cdots, \mathcal{F}_n$作为事件域独立,是指对于任意的$A_1, A_2, \cdots, A_n$,分别在$\mathcal{F}_1, \mathcal{F}_2, \cdots, \mathcal{F}_n$中,都有

$$P(\cap A_i) = \prod P(A_i)$$

Definition 2.1.5. $X_1, X_2, \cdots, X_n$独立，是指对于任意的集合$A_1, A_2, \cdots, A_n \in \mathcal{R}$中,都有

$$P(X_1 \in A_1, X_2 \in A_2, \cdots, X_n \in A_n) = \prod P(X_i \in A_i)$$

Definition 2.1.6. $A_1, A_2, \cdots, A_n$独立，是指任意的$I \subset \{1, 2, \cdots, n\}$,都有

$$P(\cap_{i \in I}) = \prod_{i \in I} P(A_i)$$

最后一个定义与之前的定义有点区别,这是因为有全集的作用:

Theorem 2.1.3. $A_1, A_2, \cdots, A_n$独立，那么

1. $A_1^c, A_2, \cdots A_n$独立
2. $1_{A_1}, 1_{A_2}, \cdots 1_{A_n}$独立

证明. 由于$A_1, A_2, \cdots, A_n$独立,所以对于任意的$I \subset \{1, 2, \cdots, n\}$,都有

$$P(\cap_{i \in I}) = \prod_{i \in I} P(A_i)$$

考虑 $A_1^c, A_2, \cdots A_n$,如果对于某个I,I中不含有1，那么

$$P(\cap_{i \in I} A_i) = \prod_{i \in I} P(A_i)$$

依旧正确.

如果I中含有1

$$P(\cap_{i \in I} A_i) = \prod_{i \in I} P(A_i)$$

$$P(\cap_{i \in I - \{1\}} A_i) = \prod_{i \in I - \{1\}} P(A_i)$$

那么

$$P(\cap_{i \in I - \{1\}} A_i \cap A_1^c) = P(\cap_{i \in I - \{1\}} A_i) - P(\cap_{i \in I} A_i) = \prod_{i \in I - \{1\}} P(A_i) - \prod_{i \in I} P(A_i) = (1 - P(A_1)) P(A_2) \cdots P(A_n)$$

所以 $A_1^c, A_2, \cdots A_n$独立.

进一步对于任意的I,$\{A_i^c, A_j : i \in I, j \in \{1, 2, 3, \cdots, n\} - I\}$是独立的,所以 $1_{A_1}, 1_{A_2}, \cdots 1_{A_n}$独立. □

2.1.1 独立的充分条件

我们的主要目的是只要检验对象上一类集合上关于独立定义的等式成立，那么我们的对象就是独立的.有必要定义：

Definition 2.1.7. $\mathcal{F}_1, \mathcal{F}_2, \cdots, \mathcal{F}_n$独立,是指对于任意的$A_1, A_2, \cdots, A_n$,分别在$\mathcal{F}_1, \mathcal{F}_2, \cdots, \mathcal{F}_n$中,都有

$$P(\cap A_i) = \prod P(A_i)$$

上一节最后的一个证明已经看出来了全集和任何一个集合独立，并且在独立上有着改变形式的微妙作用.

Lemma 2.1.4. 不失一般性，我们可以为每个$\mathcal{F}_i$添加一个全集Ω

证明. 记$\mathcal{F}_i \cup \Omega = \overline{\mathcal{F}}_i$,$\overline{\mathcal{F}}_i$独立自然推出$\mathcal{F}_i$独立.反过来也正确,因为$\cap_{i\in I} A_i \cap \Omega = \cap_{i\in I} A_i$. □

我们的结论是

Theorem 2.1.5. $\mathcal{F}_1, \mathcal{F}_2, \cdots, \mathcal{F}_n$独立,并且是$\pi$ *system*.那么$\sigma(\mathcal{F}_1), \sigma(\mathcal{F}_2), \cdots, \sigma(\mathcal{F}_n)$独立.

证明. 给定$A_2, A_3, \cdots A_n$分别在$\mathcal{F}_2, \mathcal{F}_3, \cdots \mathcal{F}_n$内,记$A = \cup A_i$.定义$\mathcal{L} = \{S : P(S \cup A) = P(S) \cup P(A)\}$.易证,$A_1 \subset \mathcal{L}$

现在证明$\mathcal{L}$是一个λ system.

首先,全集在$\mathcal{L}$中,这是显然的.

下面,$B, C \in \mathcal{L}$,$C \subset B$,$P((B-C) \cup A) = P(B \cup A - C \cup A) = P(B)P(A) - P(C)P(A) = P(B-C)P(A)$,所以$B - C \subset \mathcal{L}$

最后，如果$B_i \subset \mathcal{L}, B_i \uparrow B$,我们有$P(B_i \cap A = P(B_i)P(A)$,由概率的下连续性,左侧$\lim\limits_n P(B_i \cap A) = P(B \cap A)$,右侧$\lim\limits_n P(B_i)P(A) = P(B)P(A)$,所以$P(B \cap A) = P(B)P(A)$.

所以$\sigma(\mathcal{F}_1) \subset \mathcal{L}$,又因为$A_2, \cdots, A_n$是任取的，所以$\sigma(\mathcal{F}_1)$与$\mathcal{F}_2, \cdots, \mathcal{F}_n$是独立的.以此类推，可以证明$\sigma(\mathcal{F}_1), \sigma(\mathcal{F}_2), \cdots, \sigma(\mathcal{F}_n)$独立. □

定理的一个推论是我们这一节最重要的结果.

Theorem 2.1.6. $X_1, X_2, \cdots X_n$是一组随机变量，若对于任意的$x_1, x_2, \cdots, x_n$

$$P(X_1 \le x_1, X_2 \le x_2, \cdots, X_n \le x_n) = \prod P(X_i \le x_i)$$

那么，$X_1, X_2, \cdots X_n$独立.

证明. 由于$\{X_i \le x_i\}$是一个π system.而且$\sigma(\{(-\infty, x_i) : x_i \in \mathbb{R}\}) = \mathcal{R}$,所以$\sigma(\{\{X_i \le x_i\} : x_i \in \mathbb{R}\}) = \{\{X_i \in S\} : S \in \mathcal{R}\}$.利用上述定理，证明结论成立. □

有些时候，我们关心随机变量的运算结果的独立性,为此我们有定理

Theorem 2.1.7. 假定$\mathcal{F}_{i,j}, 1 \le i \le n, 1 \le j \le m(i)$ 是独立的事件域，令$\mathcal{G}_i = \sigma(\cup_j \mathcal{F}_{i,j})$,那么$\mathcal{G}_1, \mathcal{G}_2, \cdots \mathcal{G}_n$也是独立的.

证明. 首先构造π system 记$\mathcal{A}_i = \cap A_j$,$A_j \in \mathcal{F}_{i,j}$,这样$\mathcal{A}_i$是一个$\pi$ system,而且包含$\mathcal{F}_{i,j}$.现在证明$\mathcal{A}_i$是独立的，取$B_i \in \mathcal{A}_i$

$$P(\cap B_i) = P(\cap A_{i,j}) = \prod P(A_{i,j}) = \prod P(B_i)$$

由定理2.1.5证明结论. □

Theorem 2.1.8. 如果$1 \le i \le n, 1 \le j \le m(i)$,$X_{i,j}$独立,并且$f_i : \mathbb{R}^{m(i)} \to \mathbb{R}$可测,那么$f_i(X_{i,1}, X_{i,2}, \cdots, X_{i,m(i)})$独立.

证明. 现在$\mathcal{F}_{i,j}$是$\sigma(X_{i,j})$

$$\begin{aligned}\sigma(f_i(X_{i,1}, X_{i,2}, \cdots, X_{i,m(i)})) &= \{\{f_i(X_{i,1}, X_{i,2}, \cdots, X_{i,m(i)}) \in S\} : S \in \mathcal{R}\} \\ &\subset \{\cap\{X_i \in S_i\} : S_i \in R\} \\ &\subset A_i \\ &\subset \mathcal{G}_i\end{aligned}$$

由于$\mathcal{G}_1, \mathcal{G}_2, \cdots \mathcal{G}_n$独立，所以$f_i(X_{i,1}, X_{i,2}, \cdots, X_{i,m(i)})$独立 □

2.1.2 独立性，分布，与期望

我们研究分布和期望关于独立的性质.

粗略地说，独立的效果和直积一样，我们可以把定义在同一个空间上的独立随机变量看成是不同空间上的随机变量，他们的联合分布就是空间直积后得到的联合分布.

Theorem 2.1.9. $X_1, X_2, \cdots X_n$是一组独立的随机变量，X_i有分布μ_i,那么$(X_1, X_2, \cdots, X_n)$有分布$\mu_1 \times \mu_2 \cdots \times \mu_n$

证明.

$$P((X_1, X_2, \cdots, X_n) \in A_1 \times A_2 \times \cdots \times A_n) = P(X_1 \in A_1, X_2 \in A_2, \cdots X_n \in A_n) = \prod P(X_i \in A_i) = \prod \mu(A_i)$$

也就是，我们证明了在长方体内满足分布的要求,因此，唯一确定了$(X_1, X_2, \cdots, X_n)$有分布$\mu_1 \times \mu_2 \cdots \times \mu_n$ □

进一步，对于期望:

Theorem 2.1.10. X, Y是独立的随机变量，分别有分布μ, ν.h是一个$\mathbb{R}^2$到$\mathbb{R}$的可测函数.若$h \ge 0$,或者$E|h(X,Y)| < \infty$则:

$$Eh(X,Y) = \iint h(x,y)\mu(\mathrm{d}x)\nu(\mathrm{d}y)$$

证明.

$$\begin{aligned}Eh(X,Y) &= \int_\Omega h(X,Y)\mathrm{d}P \\ &= \int_{\mathbb{R}^2} h(x,y)(\mu \times \nu)(\mathrm{d}x \times \mathrm{d}y) && \text{用变量代换公式} \\ &= \iint h(x,y)\mu(\mathrm{d}x)\nu(\mathrm{d}y) && \text{用Fubini定理}\end{aligned}$$

□

进一步如果$h(x,y)=f(x)g(y)$
我们有$Ef(X)g(Y)=\iint f(x)g(y)\mu(\mathrm{d}x)\nu(\mathrm{d}y)=Ef(X)\int g(y)\nu(\mathrm{d}y)=Ef(X)Eg(Y)$
如果令$f=g=Id$,我们有$EXY=EXEY$
利用归纳法:

Theorem 2.1.11. 如果$X_1,X_2,\cdots,X_n$是独立的，那么

$$E(\prod X_i)=\prod EX_i$$

应当注意，反过来是不对的，我们把这种可以交换乘积和期望的性质叫做不相关.

2.1.3 独立随机变量和

独立随机变量和的分布是通过卷积得到的：

Theorem 2.1.12. 如果X,Y独立，并且有分布函数F,G,那么他们和的分布函数

$$P(X+Y\le a)=\int F(a-y)\mathrm{d}G(y)$$

证明.

$$\begin{aligned}P(X+Y\le a)&=\int_\Omega 1_{X+Y\le a}\mathrm{d}P\\&=\iint 1_{X+Y\le a}\mu(\mathrm{d}x)\nu(\mathrm{d}y)\\&=\int F(a-y)\mathrm{d}G(y)\end{aligned}$$

□

这种性质对于密度函数也是一样的:

Theorem 2.1.13. 如果X,Y独立，X有密度函数f,Y有分布函数G.那么$X+Y$有密度函数

$$h(x)=\int f(x-y)\mathrm{d}G(y)$$

进一步，如果Y有密度函数

$$h(x)=\int f(x-y)g(y)\mathrm{d}y$$

证明. 我们先求分布函数,然后把它写成积分的形式,由定理我们有

$$P(X+Y\le a)=\int F(a-y)\mathrm{d}G(y)$$

由于$F(a-y)=\int^{a-y}f(x)\mathrm{d}x$

$$P(X+Y\le a)=\int\int^{a-y}f(x)\mathrm{d}x\mathrm{d}G(y)=\int^a\int f(x-y)\mathrm{d}G(y)\mathrm{d}x$$

因而，$X+Y$有密度函数. □

2.1.4 构造独立的随机变量

在实际生活中，我们可以观察到许多独立的事件存在，但是在数学上的构造却并不容易.比较好做的是有限的情况，我们只要取$\Omega = \mathbb{R}^n$,$\mathcal{F} = \mathcal{R}^n$,取$X_i(\omega_1, \omega_2, \cdots, \omega_n) = \omega_i$.然后按照随机变量的分布给定概率测度，就完成了构造.困难的地方在于无穷的情况,有下面的定理成立，但是并不证明.

Theorem 2.1.14 (Kolmogorov's extension theorem)**.** 假定我们给出了一组在$(\mathbb{R}^n, \mathcal{R}^n)$概率测度$\mu_n$,并且有

$$\mu_{n+1}((a_1, b_1] \times (a_2, b_2] \times \cdots \times (a_{n-1}, b_{n-1}] \times \mathbb{R}) = \mu_n((a_1, b_1] \times (a_2, b_2] \times \cdots \times (a_{n-1}, b_{n-1}])$$

我们可以在$(\mathbb{R}^{\mathbb{N}}, \mathcal{R}^{\mathbb{N}})$定义一个唯一的概率测度$P$,满足，$P(\omega : \omega_i \in (a_i, b_i], 1 \geq i \geq n) = \mu_n((a_1, b_1] \times (a_2, b_2] \times \cdots \times (a_{n-1}, b_{n-1}])$

2.2 弱大数定律

所谓的“弱”,说的是依概率收敛.

Definition 2.2.1. $Y_n \to Y$,依概率,是指对于任意$\epsilon > 0$

$$P(|Y_n - Y| \geq \epsilon) \to 0$$

2.2.1 L2 弱收敛定律

L收敛可以推出P收敛,具体地说

Theorem 2.2.1. $p > 0$,如果$E|X_n|^p \to 0$,那么X_n依概率收敛到0

证明. $P(|X_n| \geq \epsilon) \leq \dfrac{E|X|^p}{\epsilon^p} \to 0$ □

Theorem 2.2.2 (L^2 Weak Law)**.** 假设$X_1, X_2, \cdots X_n$不相关,$EX_i = \mu$,$\mathrm{Var}X_i \leq C$,则$\sum X_i/n \to \mu$ 依概率.

证明.

$$P(|\sum X_i/n - \mu| \geq \epsilon) \leq \frac{E\sum X_i - \mu}{n^2\epsilon^2} = C/n\epsilon^2 \to 0 \quad n \to 0$$

□

下面是两个例子

Example 2.2.1. f是一个$[0, 1]$上的连续函数,并且令

$$f_n(x) = \sum_{m=0}^{n} \binom{n}{m} x^m (1-x)^{n-m} f(m/n)$$

那么当$n \to \infty$时，$\sup_{x \in [0,1]} |f_n(x) - f(x)| \to 0$.

Solution 2.2.1. 首先考虑$X_1, X_2, \cdots X_n, \cdots$,i.i.d.并且

$$P(X_i = 1) = p \quad P(X_i = 0) = 1 - p$$

那么$f_n(p) = Ef(S_n/n)$,现在估计f_n与f的误差:

$$\begin{aligned}|Ef(S_n/n) - f(p)| &\le E|f(S_n/n) - f(p)| \\ &= E(|f(S_n/n) - f(p)|, |f(S_n/n) - f(p)| \le \epsilon) + E(|f(S_n/n) - f(p)|, |f(S_n/n) - f(p)| \ge \epsilon) \quad \le \epsilon\end{aligned}$$

由于f一致连续，故$|f(S_n/n) - f(p)| \ge \epsilon$,一定有$\delta$,$|S_n/n - p| \ge \delta$.
而$P(|S_n/n - p| \ge \delta) \le \dfrac{p(1-p)}{\delta^2 n} \le \dfrac{1}{\delta^2 n}$.
故取足够大的n,有$P(|f(S_n/n) - f(p)| \ge \epsilon) \le P(|S_n/n - p| \ge \delta) \le \epsilon$. 因此

$$|Ef(S_n/n) - f(p)| \le \epsilon + 2M\epsilon$$

完成证明. □

Example 2.2.2. 一个高维立方体几乎就是一个球体的边界 令$X_1, X_2, X_3, \cdots X_n \cdots$,i.i.d.而且为$(-1, 1)$区间上的均匀分布，令$Y_i = X_i^2$,$EY_i^2 = 1/3$,那么$\sum Y_i/n \to 1/3$,取$\epsilon$,记$A_{n,\epsilon} = \{x \in \mathbb{R}^n : (1-\epsilon)\sqrt{n/3} < |x| < (1+\epsilon)\sqrt{n/3}\}$,由上面的结论,$|A_{n,\epsilon} \cap (-1,1)^n|/2^n \to 1$.也就是说这个高维立方体的大部分体积都落在了这个球体的边界上.

2.2.2 三角阵列

现在考虑三角阵列

$$\begin{array}{lll} X_{1,1} & & \\ X_{2,1} & X_{2,2} & \\ X_{3,1} & X_{3,2} & X_{3,3} \\ \cdots & & \end{array}$$

图 2.1: 三角阵列

我们要求每一列的随机变量都是独立的.

Theorem 2.2.3. 令$S_n = \sum_{i=1}^n X_{n,i}$,记$\mu_n = ES_n$,$\sigma_n^2 = \mathrm{Var}S_n$,如果$\sigma_n^2/b_n^2 \to 0$,那么$\dfrac{S_n - \mu_n}{b_n} \xrightarrow{P} 0$

证明.

$$P(|\frac{S_n - \mu_n}{b_n}| \ge 0) \le \frac{\sigma_n}{b_n^2} \to 0$$

□

下面是关于这个定理的例子.

Example 2.2.3. 收集卡片 $X_1, X_2, \cdots, X_n, \cdots$,i.i.d.在$\{1, 2, 3 \cdots n\}$上均匀分布，代表每一次收集卡片每张卡片出现的概率都是相等的.记$\tau_k^n = \inf\{m : |\{X_1, X_2, \cdots, X_m\}| = k\}$是第一次获得$k$张不同卡片的步数.我们考虑$T_n = \tau_n^n$的渐进行为.

首先可以记$Y_{n,k}=\tau_k^n-\tau_{k-1}^n$,那么$Y_{n,k}$满足参数为$1-\frac{k-1}{n}$的几何分布.$E(Y_{n,k})=(1-\frac{k-1}{n})^{-1}$,$E(Y_{n,k}^2)\leq(1-\frac{k-1}{n})^{-2}$,所以$ET_n=\sum(1-\frac{k-1}{n})^{-1}$, $\mathrm{Var}(T_n)\leq\sum(1-\frac{k-1}{n})^{-2}$.

所以$ET_n\sim n\log n$,$\mathrm{Var}(T_n)\leq Cn^2$.取$b_n=n\log n$,立刻得到：

$$T_n/n\log n\xrightarrow{P}1$$

Example 2.2.4. 排列 一个排列可以写成多个轮换的积,现在假定所有的排列都是等可能的,我们令$X_{n,k}$为n元排列在第k个数后面出现括号的随机变量(如果出现，则取1，否则就取0).那么$S_n=\sum X_{n,i}$,就代表了这个排列的循环的个数.我们研究S_n的渐进性质.

Lemma 2.2.4. $X_{n,1},X_{n,2},\cdots,X_{n,n}$是独立的，而且$P(X_{n,j}=1)=\dfrac{1}{n-j+1}$

证明. 证明的核心在于选取合适的排列的表示方式,我们按照映射的方式表示排列.首先我们把1作为开头,如果1的后继是1，那么第二个数选2,否则第二个数就选1的后继,以此类推，直到把从1到n的后继都写出来.

1 3 2 4 9 5 7 6

3 2 1 9 4 7 6 5

图 2.2: 例子

现在考虑$P(X_{n,j})$,不管前面是如何选取数字的，在第j个位置,只有$n-j+1$个数字可供选择，其中只有1种选择可以在j后面加括号.所以我们证明了独立性与概率$P(X_{n,j}=1)=\dfrac{1}{n-j+1}$. □

现在来考虑极限

$$ES_n=\sum\frac{1}{n-j+1}\sim\log n$$

$$\mathrm{Var}(S_n)=\sum\mathrm{Var}(X_{n,i})\leq\sum EX_{n,i}^2=ES_n\sim\log n$$

取$b_n=(\log n)^{0.5+\epsilon}$,我们得到

$$\frac{S_n}{(\log n)^{0.5+\epsilon}}\to 1$$

Example 2.2.5. 球箱问题 我们把r个球放在n个箱子里，我们想知道空箱子的个数,令A_i是第i个箱子空了的事件,N_n是空箱子的个数.显然

$$P(A_i)=(1-1/n)^r\quad EN_n=n(1-1/n)^r$$

$$EN_n^2=\sum P(A_{n,i})+\sum P(A_{n,j}\cap A_{n,k})=n(1-1/n)^r+(n^2-n)(1-2/n)^r$$

$$\mathrm{Var}(N_n)=n(1-1/n)^r+(n^2-n)(1-2/n)^r-n^2(1-1/n)^2r$$

所以$\mathrm{Var}(N_n)/n^2\to 0$,$S_n/n\to e^{-c}$(如果我们令$r/n=c$).

2.2.3 截断

为了进一步减弱大数定律的条件,我们采用截断的操作.所谓的截断,就是对随机变量的取值做分割,暂时抛掉随机变量取值较大的部分,获得有界的变量.

$$\overline{X} = X1_{|X|\le M}$$

下面陈述理论上的一个渐进估计

Theorem 2.2.5. *考虑三角阵列,选取b_n,使得$\overline{X}_{n,k} = X_{n,k}1_{|X_{n,k}|\le M}$.如果满足:*

1. $\sum P(|X_{n,k}| > b_n) \to 0$
2. $b_n^{-2}\sum E\overline{X}_{n,k}^2 \to 0$

再记$a_n = \sum E\overline{X}_{n,k}$,我们有$\dfrac{S_n - a_n}{b_n} \to 0$

证明. 现在,对$P(|\dfrac{S_n - a_n}{b_n}| \ge \epsilon)$做估计.

$$\begin{aligned}
P(|\frac{S_n - a_n}{b_n}| \ge \epsilon) \le & P(|\frac{\overline{S}_n - a_n}{b_n}| \ge \epsilon) + P(S_n \ne \overline{S}_n) \\
\le & \frac{\sum E\overline{X}_{n,k}^2}{\epsilon^2 b_n^2} + \sum P(|X_{n,k}| > b_n) \\
\to & 0
\end{aligned}$$

□

如果我们用在大数定律上,可以得到下面两个结论

Theorem 2.2.6. *$X_1, X_2, \cdots, X_n, \cdots$,是一列独立同分布的随机变量,满足:*

$$xP(|X_i| > x) \to 0$$

如果记$\mu_n = \sum E\overline{X}_k$,那么$\dfrac{S_n - \mu_n}{n} \to 0$

证明. 我们只需要证明上面的两条性质成立,取$b_n = n$,有

$$\sum P(|X_k| > n) = nP(|X_k| > n) \to 0, \quad n \to 0$$

为解决第二个问题,我们需要证明下面的一个有用的公式

Lemma 2.2.7. *$X \ge 0$,$EX^p = \int py^{p-1}P(X > y)\mathrm{d}y$*

证明.

$$EX^p = \int x^p \mathrm{d}P = \int\int^x py^{p-1}\mathrm{d}y\mathrm{d}P = \int py^{n-1}\int 1_{X>y}\mathrm{d}P = \int py^{p-1}P(X > y)\mathrm{d}y$$

□

下面考虑$n^{-2}\sum E\overline{X}_k^2 = n^{-1}E\overline{X}_k^2 \le n^{-1}\int^n 2yP(X\ge y)\mathrm{d}y \to 0$.

我们因此得到结论.

□

Theorem 2.2.8. $X_1, X_2, \cdots, X_n, \cdots$,是一列独立同分布的随机变量,满足$EX_i = \mu$,则

$$\frac{S_n}{n} \to \mu$$

证明. $E(|X_i|||X_i| > x) \to 0 \quad x \to \infty$,而$E(|X_i|||X_i| > x) \ge xP(|X_i| > x)$,所以$xP(|X_i| > x) \to 0$.从而得到结论. □

Example 2.2.6. The "St.Petersburg paradox" 这个例子是说即使我们可能没有一阶矩,但是我们依旧可以得到大数定律.核心的方法就是使用我们这一节最开始的定理.

现在考虑一组独立同分布的随机变量X_i,满足下列分布：

$$P(X_i = X^j) = 2^{-j}$$

那么通过计算,$EX_i = \infty$.如果这是一场赌博游戏，那么我们能够期望得到的金钱应该是无穷，如果收费玩这场游戏，无论收多少钱，我们都有正的期望的收益.但事实并非如此.

因为我们可以选取合适的b_n.首先计算$P(X_i \ge 2^m) = 2^{-m+1}$.令$m(n) = \log n + K(n)$,我们要求$K(n) \to \infty$.令$b_n = 2^m(n)$.

计算第一个要求,$\sum P(X_i \ge b_n) = n2^{-b(n)+1} = 2^{-K(n)+1} \to 0$.

计算第二个要求,$b_n^{-2}\sum E\overline{X}_i = b_n^{-2}n\sum_1^{m_n} 2^{2j}2^{-j} \le 2b_n^{-1}n \to 0$.

由于$E\overline{X} = m(n)$.所以$\dfrac{S_n - nm(n)}{b_n} \to 0$.现在取$K(n) = \log\log n$. 我们立刻得到$\dfrac{S_n}{n\log n} \to 1$.我们可以大致地说,玩$n$次这个游戏,我们大致能得到的钱是$n\log n$.当然这个估计是非常粗略的,首先，我们需要足够大的n来保证在一个较大的概率下这个$\dfrac{S_n}{n\log n} \in (1-\epsilon, 1+\epsilon)$.也就是说,我们真正估计出来的范围是很大的.此外,如果我们加减一个小的无穷大量,对渐进行为没有影响,但其实我们已经差了很多很多钱了.

2.3 Borel-Cantelli 引理

我们从现在开始研究强大数定律,也就是几乎必然收敛意义下的强大数定律.为了研究几乎必然收敛,我们一定要将它与概率的计算建立起联系.

第一步操作是建立起几乎必然收敛的等价说法,假设$X_n \xrightarrow{a.s.} 0$,也就是说$P(\lim\limits_{n\to 0} X_n = 0) = 1$. 事件$\lim\limits_{n\to 0} X_n \ne 0$等于$\cup_N \cap_m \cup_{n>m}\{|X_n| \ge 1/N\}$,也就是说对于任何的$\epsilon$,有$P(\{\cap_m \cup_{n>m} \{|X_n| \ge \epsilon\}) = 0$.也就是说$P(|X_n| \ge 0\ i.o.) = 0$.

而Borel-Cantelli 引理为我们提供了解决判断$P(|X_n| \ge 0\ i.o.) = 0$是否成立的一个办法.

Theorem 2.3.1. 一列事件A_i,满足$\sum P(A_i) < \infty$,那么$P(A_n\ i.o.) = 0$

证明. 假设$N = \sum 1_{A_i}$ 如果$P(A_n\ i.o.) > 0$,那么$EN = \infty$.然而$EN = \sum E1_{A_i} = \sum P(A_i) < \infty$.矛盾. □

对于独立的情况我们可以做更多的事情.

Theorem 2.3.2. 一列事件A_i独立,满足$\sum P(A_i)=\infty$,那么$P(A_n\ i.o.)=1$

证明. 我们要充分利用独立的性质.考虑$P(\cap_M^N A_i^c)=\prod(1-P(A_i))\le\prod\exp(\log(1-P(A_i)))\le\exp(\sum -P(A_i))\to 0$

所以$\lim\limits_{N\to\infty}P(\cup_M^N A_n)\to 1$.因此$P(A_n,i.o.)=1$ □

下面来研究依概率收敛和几乎必然收敛的关系.利用我们第二段的等价描述，不难发现几乎必然收敛可以推出依概率收敛.所以重要的问题是,依概率收敛在什么程度上可以推出几乎必然收敛.我们首先给出一个有用的收敛定理.

Lemma 2.3.3. 在一个拓扑空间中的数列y_n收敛于y,当且仅当y_{nk}子列中总有子列的子列y_{nkm}是收敛的.

Theorem 2.3.4. $X_n\xrightarrow{P}X$当且仅当任取子列X_{nk},都有一个几乎必然收敛到X的子列X_{nkm}

证明. 首先假设有$X_n\xrightarrow{P}X$,我们取子列X_{nk},依旧有$X_{nk}\xrightarrow{P}X$,任取ϵ,取nkm使得$P(|X_{nkm}-X|\ge\epsilon)\le 2^{-m}$.所以找到了$X_{nkm}$几乎必然收敛.

反过来考虑$y_n=P(|X_n-X|\ge\epsilon)$,由于任取子列$X_{nk}$,都有一个几乎必然收敛到$X$的子列$X_{nkm}$,所以$y_{nkm}\to 0$,所以$y_n\to 0$.即依概率收敛. □

现在我们来证明第一个强大数定律,这个证明很简单，因为我们给出了直接让结论成立的条件.

Theorem 2.3.5. $X_1,X_2,\cdots X_n,\cdots$是一组独立同分布的随机变量.现在要求四阶矩存在$EX^4<\infty$,记$EX=\mu$,我们有

$$\frac{S_n}{n}\to\mu$$

证明. 不失一般性，假定$\mu=0$.现在估计

$$P(|S_n/n|\ge\epsilon)\le\frac{ES_n^4}{n^4\epsilon^4}$$

我们考察ES_n^4中的各项.首先因为$EX=0$,所以但凡含有奇数阶的项一定是零.

所以,如果我们选取足够大的C,$ES_n^4=nEX^4+3(n^2-n)EX^2\le Cn^2$.

那么推出$\sum P(|S_n/n|\ge\epsilon)<\infty$.因而证得命题成立. □

下面一个定理是对第二Borel-Cantelli引理的应用

Theorem 2.3.6. 如果$X_1,X_2,\cdots X_n$是$i.i.d$的,$EX=\infty$.那么$P(|X_n|>n\quad i.o.)=1$.而且$P(\lim S_n/n$存在$\in(-\infty,\infty))=0$

证明. $EX\le\sum_{n=0}^{\infty}P(|X|>n)$.又因为同分布，$\sum P(|X_i|>i)=\infty$,所以$P(|X_n|>n\ \ i.o.)=1$.

现在来证明第二个结论 □